

Named Entity Recognition в текстах Ф. М. Достоевского

Демидова Екатерина

pass by and wait until she went out again. But what if meanwhile, starts shouting - there is suspicion for you, or at least the gr are still trifles he had not even begun to think about, nor did t the main thing, and put the trifles off until he himself was i this last seemed decidedly unresolvable. At least it seemed so ne, for example, that one day he would finish thinking, get his recent trial (that is, his visits with the intention of makin e) was only a trying out and far from the real thing, a lf: "Why not go and try it - enough of this dreaming!" and endure it, spit, and spit, furious with himself. And yet it w led the whole analysis, in terms of the moral resolution of th arps as a razor, and he no longer found any conscious obj mee he simply did not believe himself, and stubbornly, st e sides, graspingly, as if someone were forcing him and d ay, which had come so much by chance and resolved everyt most wholly mechanically! as if someone had taken him by y irresistibly, blindly, with unnatural force, without object thing had been caught in the coils of a machine and he w first - even long before - he had been occupied with one g anals leave such an obviously marked trail, and why alm icked and solved. He came gradually to various and cu reason lying in his opinion, not so much in the materia the crime as in the criminal himself: himself, almost t the moment of the crime, a sort of failure of will an y, are replaced by a phenomenal, childish thoughtless, in reason and prudence are most necessary. Accordi l out that this darkening of reason and failure of will, seast, develop gradually, and reach their height short



Постановка задачи

Цель: найти наиболее частотные именованные сущности разных типов в творчестве Ф. М. Достоевского.

План работы:

- 1) Создать датафрейм с текстами Достоевского, провести препроцессинг;
- 2) Дообучить и протестировать существующую языковую модель для NER на размеченном корпусе русских текстов;
- 3) Применить модель к основному датафрейму и получить топ-10 сущностей с разными тегами для всех текстов;
- 4) Визуализировать результаты;
- 5) Оценить точность результатов на основе личного опыта изучения творчества Достоевского.





Материал

Источник текстов (prose → Dostoevsky):

<https://www.kaggle.com/datasets/d0rj3228/russian-literature>

(отдельно – текст «Преступления и наказания»:

<https://www.kaggle.com/datasets/timmofeyy/crime-and-punishment-full-book-in-original/data>)

В объединенном датафрейме 34 текста Достоевского с 1846 по 1881 год, включая рассказы, повести, романы и «Дневник писателя».

Я вручную удалила из текстов имя автора, примечания, комментарии и вступ. статьи (если они были).



Подготовка модели

Модель: <https://huggingface.co/DeepPavlov/rubert-base-cased>

Размеченный корпус: <https://github.com/razmecheno/main/blob/main/data.tsv>

- Русские дневники XX века из архива проекта «Прожито».
- 5 типов сущностей: person (PER), characteristics (CHAR), location (LOC), organisation (ORG), facility (FAC).

(Подробнее о корпусе: <https://arxiv.org/pdf/2201.09997>)

Обоснование подхода: дневники по своему стилю (неформальность, субъективность, эмоциональность) лучше подходят для решения нашей задачи, чем вики- и новостные статьи, на которых обучена модель.




Оценка модели

Показатели качества после трёх эпох обучения:

Epoch	Training Loss	Validation Loss	Precision	Recall	F1	Accuracy
1	0.176800	0.140281	0.744292	0.754630	0.749425	0.969112
2	0.090700	0.132971	0.757322	0.837963	0.795604	0.969836
3	0.064700	0.131862	0.761506	0.842593	0.800000	0.969836

Тестовый пример обработки:

Текст: Князь Андрей Болконский прибыл в поместье Лысые Горы
Обнаруженные сущности:
Князь → CHAR (confidence: 0.73)
Андрей Болконский → PER (confidence: 0.99)
поместье Лысые Горы → LOC (confidence: 0.86)



Обработка корпуса

Препроцессинг: удаление переносов строк и лишних пробелов, сегментация на предложения (как в обучающем корпусе) — с помощью `re` и `razdel`.


Нормализация сущностей: лемматизация, приведение к нижнему регистру (кроме имен собственных) — с помощью `rumorphy2`.

После извлечения и подсчета сущностей стало ясно, что сущности с тегами `ORG` и `PER` малоинформативны: названия организаций упоминаются крайне редко (почти исключительно в «Дневнике писателя»), а имена персонажей не дают ценной характеристики творчества автора.


Для визуализации я решила использовать сущности типа `CHAR`, `LOC` и `FAC`.




Топ-10 персонажей в текстах Достоевского




Топ-10 локаций в текстах Достоевского



Топ-10 организаций в текстах Достоевского





Оценка результатов

Полученные результаты кажутся достаточно правдоподобными для творчества Достоевского:

- ✓ Устойчива тема семьи, «отцов и детей»; большое значение имеет образ ребенка;
- ✓ Превалирует городское, особенно петербургское пространство; важен образ России, проблема взаимоотношений России и Европы;
- ✓ Заметен интерес автора к театру, религии (образы церкви, монастыря), образованию (школа, гимназия, университет).





Перспективы

В продолжение исследования было бы интересно:

- 1) Выявить ключевые слова из контекста, в котором чаще всего фигурируют те или иные сущности (для всего корпуса или для отдельных текстов);
 - 2) Провести анализ тональности предложений, в которых встречаются определенные сущности, и сравнить их (например, Петербург и Москву);
 - 3) Посмотреть на динамику частотности сущностей в разные периоды творчества автора.
- 
- 